

Derin Öğrenme Tabanlı Tıbbi Görüntülerde Böbrek Taşı Tespiti Uygulaması

Cihangir Emre Er, Tuna Kömür

Son yıllarda tıbbi görüntüleme teknolojilerindeki ilerlemeler, yapay zeka temelli analiz yöntemlerinin klinik tanı süreçlerinde etkin biçimde kullanılmasına olanak tanımıştır. Bu araştırmanın temel amacı, Bilgisayarlı Tomografi (BT) görüntülerinde böbrek taşlarının otomatik olarak tespit edilmesini sağlayan bir sistem geliştirerek, radyologların ve ürologların tanı süreçlerindeki iş yükünü azaltmak ve klinik karar verme aşamasında onlara güvenilir bir yardımcı araç sunmaktır. Çalışma kapsamında normalizasyon, ilgi alanı (ROI) çıkarımı ve veri artırma adımları uygulanarak hibrit modellerin performansı değerlendirilecektir.

1 Giriş

1.1 Konunun Önemi

Böbrek hastalıklarının erken teşhisi, hem hastaların yaşam kalitesini artırmak hem de sağlık sistemi üzerindeki mali yükü azaltmak açısından kritik bir öneme sahiptir. Böbrek taşları ve tümörleri dünya genelinde yaygın görülen sağlık sorunlarıdır. Modern tıpta BT, yüksek çözünürlüklü görüntüleme sağlaması nedeniyle bu patolojilerin teşhisinde altın standart olarak kabul edilmektedir. Ancak, radyologların incelemesi gereken görüntü hacminin her geçen gün artması, manuel değerlendirme süreçlerinde insan kaynaklı hata payını ve tanı gecikmelerini beraberinde getirmektedir.

1.2 Problemin Tanımı

Klinik ortamda böbrek taşları ve tümörleri bazen benzer belirtiler gösterebilmekte, bu da yanlış teşhis veya zaman kaybına yol açabilmektedir. Özellikle küçük boyutlu patolojilerin gözden kaçma riski, tedavinin başarısını olumsuz etkilemektedir. Mevcut iş akışında radyolog deneyimine dayalı manuel analizler, artan iş yükü altında sürdürülebilirlik açısından zorluklar yaratmaktadır. Bu nedenle, BT görüntülerindeki patolojileri otomatik, hızlı ve yüksek doğrulukla tespit edebilen sistemlere ihtiyaç duyulmaktadır.

1.3 Literatür

Xie vd. (2023) tarafından sunulan kapsamlı literatür taraması, tıbbi görüntü segmentasyonunda "Attention" mekanizmalarının ve Transformer tabanlı mimarilerin sağladığı başarıları kategorize ederek incelemektedir. Çalışma, özellikle evrişimli sinir ağlarının (CNN) yerel özellik çıkarma sınırlamalarını aşmak için kullanılan dikkat mekanizmalarının; medikal görüntülerdeki uzun menzilli bağımlılıkları yakalama ve karmaşık dokusal yapıları ayırt etme yeteneğini vurgulamaktadır[1].

Santhosh vd. (2023) tarafından sunulan çalışmada, BT tarama görüntülerinde böbrek taşı tespiti için CNN ve Destek Vektör Makinesi (SVM) algoritmalarını birleştiren hibrit bir model önerilmiştir. Kaggle üzerinden temin edilen 12.446 görüntülik kapsamlı bir veri seti kullanılan araştırmada, görüntü iyileştirme için Medyan Filtre ve normalizasyon gibi ön işleme adımları uygulanmıştır. Çalışmanın en önemli başarısı, hibrit mimarinin tek başına CNN kullanımına kıyasla daha yüksek bir performans sergileyerek %97,9 doğruluk oranına ulaşmasıdır[2].

Akshaya vd. (2020) tarafından gerçekleştirilen çalışmada, Manyetik Rezonans (MR) görüntülerinden otomatik böbrek taşı sınıflandırması yapmak amacıyla Geri Yayılım Ağı (Back Propagation Network - BPN) tabanlı bir yapay sinir ağı modeli kullanılmıştır. Araştırmada, MR görüntülerindeki gürültülerin elenmesi için Medyan Filtre uygulanmış ve özellik çıkarımı aşamasında piksellerin kümelenmesi için Bulanık C-Ortalamalar (Fuzzy C-Means - FCM) algoritmasından yararlanılmıştır. Çalışmanın başarısı, geleneksel manuel inceleme yöntemlerine göre daha hızlı ve tutarlı bir ROI süreci sunmasıdır[3].

Rajput vd. (2021) tarafından gerçekleştirilen çalışma, genellikle yüksek gürültü içeren ultrason (USG) görüntülerinde böbrek taşlarının manuel müdahale olmaksızın otomatik olarak tespit edilmesine odaklanmıştır. Araştırmada derin öğrenme modelleri yerine; speckle gürültüsünü azaltmaya yönelik görüntü iyileştirme, segmentasyon ve morfolojik analizleri içeren geleneksel görüntü işleme algoritmaları tercih edilmiştir. Çalışmanın başarısı, %100 hassasiyet (sensitivity) değeri ile taş vakalarını yakalamadaki yüksek performansdır; ancak özgüllük (specificity) değerinin %50 ve genel doğruluğun %80 düzeyinde kalması, sistemin yanlış pozitiflere karşı hassas olduğunu göstermektedir[4].

Yıldırım vd. (2021) tarafından gerçekleştirilen çalışmada, koronal BT görüntüleri üzerinden böbrek taşlarının otomatik tespiti için ResNet tabanlı bir derin öğrenme modeli olan XResNet-50 mimarisi geliştirilmiştir. 433 hastadan elde edilen 1799 görüntüden oluşan geniş bir veri setiyle eğitilen model, %96,82 oranında yüksek bir genel doğruluk değerine ulaşmıştır. Araştırmanın en önemli katkılarından biri, Grad-CAM (Gradient-weighted Class Activation Mapping) gibi görsel açıklanabilirlik tekniklerini kullanarak modelin karar verme aşamasında odaklandığı bölgeleri (ısı haritaları) şeffaflaştırmasıdır[5].

Chlap vd. (2021) tarafından sunulan kapsamlı derleme çalışması, tıbbi görüntüleme alanında derin öğrenme modellerinin performansını ve genelleme yeteneğini artırmak için kullanılan veri artırma (data augmentation) tekniklerini sistematik olarak incelemektedir. Çalışma; temel geometrik dönüşümlerden (döndürme, ölçekleme), yoğunluk değişimlerine ve Üretken Çekişmeli Ağlar (GAN) gibi ileri düzey sentetik veri üretim

yöntemlerine kadar geniş bir yelpazeyi ele alarak, bu tekniklerin kısıtlı tıbbi veri setlerindeki aşırı uyum (overfitting) problemini aşmadaki kritik rolünü vurgulamaktadır. Tıbbi görüntülemelerde veri artırmanın klinik doğruluğu doğrudan etkilediğini kanıtlayan bu çalışma, projemizde uygulanacak olan veri artırma hattı için güçlü bir teorik temel sunmaktadır[6].

Bu çalışmada, sınırlı tıbbi veri setlerinde böbrek taşı tespiti başarısını artırmak amacıyla Transfer Öğrenme (*Transfer Learning*) metodolojisi kullanılarak VGG16, ResNet50 ve InceptionV3 gibi önceden eğitilmiş derin öğrenme mimarileri karşılaştırılmıştır. Araştırma, ImageNet gibi devasa veri setlerinde eğitilmiş ağırlıkların tıbbi görüntülere aktarılmasının, eğitim süresini kısalttığını ve genelleme yeteneğini artırdığını nicel verilerle kanıtlamaktadır. Çalışmanın temel başarısı, derin öğrenme modellerinin tıbbi uzman eksikliğini gidermedeki potansiyelini vurgulamasıdır[7].

Elton vd. (2022) tarafından gerçekleştirilen bu kapsamlı çalışma, kontrastsız BT taramalarında böbrek taşlarının otomatik tespiti ve hacimsel segmentasyonu için üç aşamalı bir derin öğrenme sistemi önermektedir. Araştırmada, böbrekleri yerleştirmek için bir CNN, taş adaylarını belirlemek için bir 3D segmentasyon ağı ve yanlış pozitifleri elemeyi amaçlayan bir sınıflandırma ağı kullanılmıştır. Çalışmanın en önemli başarısı, manuel ölçümlere kıyasla taş hacmini %94,2 oranında benzer bir doğrulukla hesaplayabilmesi ve radyologların iş yükünü önemli ölçüde azaltma potansiyeli sunmasıdır[8].

Goceri (2023) tarafından sunulan bu kapsamlı derleme çalışması, böbrek taşı tespiti ve segmentasyonunda kullanılan derin öğrenme tabanlı güncel metodolojileri, veri setlerini ve performans değerlendirme kriterlerini sistematik bir perspektifle incelemektedir. Çalışma, özellikle U-Net türevleri gibi mimarilerin tıbbi görüntü segmentasyonundaki başarısını ve hiper-parametre optimizasyonunun model hassasiyeti üzerindeki kritik etkisini vurgulamaktadır. Araştırmanın başarısı, mevcut literatürdeki boşlukları (veri dengesizliği, anotasyon eksikliği vb.) belirleyerek gelecekteki çalışmalar için kapsamlı bir yol haritası sunmasıdır[9].

Nagaraju vd. (2022) tarafından sunulan çalışmada, BT görüntülerinde böbrek taşı tespiti için makine öğrenmesi ve derin öğrenme tekniklerini birleştiren çok seviyeli bir yaklaşım önerilmiştir. Araştırmada, gürültü giderme için anizotropik difüzyon filtresi kullanılmış ve özellik ayıklama aşamasında hem geleneksel doku özellikleri hem de CNN elde edilen derin özellikler entegre edilmiştir. Çalışmanın başarısı, farklı sınıflandırıcıların (SVM, Random Forest vb.) performansını karşılaştırarak hibrit özellik çıkarımının teşhis doğruluğu üzerindeki olumlu etkisini göstermesidir[10].

Akkasaligar vd. (2017) tarafından gerçekleştirilen çalışmada, BT görüntülerinde böbrek taşlarının yerini ve boyutunu belirlemek amacıyla görüntü işleme tabanlı bir yaklaşım önerilmiştir. Araştırmada, görüntüyü odaklamak için kırpma (*cropping*) işlemi uygulanmış, ardından FCM kümeleme yöntemi ve Level Set segmentasyonu kullanılarak taş pikselleri izole edilmiştir. Çalışmanın başarısı, karmaşık segmentasyon problemlerini matematiksel modellerle çözerek taşın (X, Y) koordinatlarını ve alanını başarıyla raporlamasıdır[11].

Bu çalışmada, BT görüntülerinde farklı boyutlardaki böbrek taşlarının tespit başarısını artırmak amacıyla çok ölçekli özellik füzyonu (*multi-scale feature fusion*) tabanlı bir derin öğrenme yaklaşımı önerilmiştir. Araştırmanın temel başarısı, piramit

özellik ağları (FPN) benzeri bir yapı kullanarak hem küçük boyutlu taş piksellerini hem de geniş dokusal bağlamı aynı anda işleyebilmesi ve bu sayede tespit hassasiyetini artırmasıdır[12].

Bu çalışmada, tıbbi görüntülerde böbrek taşı tespiti için farklı CNN modellerinin performansı karşılaştırmalı olarak incelenmiş ve derin öğrenme modellerinin teşhis süreçlerindeki doğruluğu değerlendirilmiştir. Araştırmanın başarısı, standart derin öğrenme mimarilerinin manuel radyolojik incelemelere kıyasla daha hızlı sonuç üretebildiğini ve tutarlı bir performans sergilediğini ortaya koymasındır[13].

Bu çalışmada, BT görüntülerinden böbrek taşı tespiti için geleneksel görüntü işleme teknikleri ile istatistiksel tabanlı bir yapay sinir ağı olan Olasılıksal Sinir Ağı (PNN) kombinasyonu kullanılmıştır. Araştırmada, taş bölgelerini izole etmek için havza (*watershed*) segmentasyon algoritması uygulanmış ve bu bölgelerden elde edilen doku öznitelikleri PNN modeline girdi olarak verilmiştir. Çalışmanın başarısı, PNN mimarisinin hızlı eğitim süresi sayesinde taşlı ve normal dokuları ayırt edebilmesidir[14].

Vasanthi vd. (2025) tarafından gerçekleştirilen çalışmada, BT görüntüleri üzerinde böbrek taşlarının gerçek zamanlı nesne tespiti için Transformer tabanlı RT-DETR (Real-Time Detection Transformer) mimarisinin etkinliği incelenmiştir. Araştırma, RT-DETR modelinin çok ölçekli özellik etkileşimi (multiscale feature interaction) yeteneği sayesinde, geleneksel YOLO modellerinden farklı olarak "Non-Maximum Suppression" (NMS) işlemine ihtiyaç duymadan yüksek doğruluk ve düşük gecikme süresiyle taş tespiti yapabildiğini kanıtlamaktadır. Çalışmanın başarısı, modelin küresel bağlamı (global context) anlama kapasitesi sayesinde küçük ve düşük kontrastlı taşları tespit etmedeki hassasiyetidir[15].hocanın pdf

Zhu vd. (2021) tarafından sunulan çalışmada, geleneksel Transformer tabanlı nesne tespiti modellerinin yüksek hesaplama maliyeti ve yavaş yakınsama sorunlarını aşmak amacıyla Deformable DETR mimarisi önerilmiştir. Araştırma, dikkat (attention) mekanizmasının görüntünün tamamı yerine sadece belirli anahtar örnekleme noktalarına odaklanmasını sağlayan "deformable" yaklaşımını tanıtarak, özellikle küçük ölçekli nesnelerin tespitinde yüksek performans sergilemiştir. Çalışmanın en önemli başarısı, düşük hesaplama yüküyle yüksek çözünürlüklü özellik haritalarını işleyebilmesidir[16].nesnetespit1

Boriceanu vd. (2025) tarafından gerçekleştirilen çalışmada, BT taramalarında böbrek taşı teşhisini otomatize etmek amacıyla en güncel nesne tespiti algoritmalarından biri olan YOLOv11 mimarisinin performansı değerlendirilmiştir. Araştırma, YOLOv11'in derin özellik çıkarım kapasitesi ve optimize edilmiş mimarisi sayesinde, özellikle kist ve tümör gibi benzer dokusal özelliklere sahip yapılar arasından böbrek taşlarını yüksek doğrulukla ayırt edebildiğini ortaya koymaktadır. Çalışmanın en önemli başarısı, modelin tıbbi veri setlerindeki farklı sınıfları yüksek hızda kategorize edebilmesidir[17].

Li vd. (2024) tarafından gerçekleştirilen araştırmada, BT görüntülerinde patolojik nesne tespiti başarısını optimize etmek amacıyla YOLOv8 ve YOLOv10 modellerinin performansları karşılaştırmalı olarak analiz edilmiştir. Çalışma, YOLOv10'un "dual-label assignment" stratejisi sayesinde eğitim sürecindeki verimliliği artırdığını ve tıbbi görüntülerdeki nesne sınırlarını belirlemede YOLOv8'e oranla daha dengeli sonuçlar

verdiğini ortaya koymaktadır. Araştırmanın temel başarısı, sınıf dengesizliği olan tıbbi veri setlerinde modelin genelleme yeteneğini artıran kayıp fonksiyonları (loss functions) önermesidir[18].nesnetespit3

Wang vd. (2023) tarafından sunulan çalışmada, gerçek zamanlı nesne tespiti performansını artırmak amacıyla Transformer tabanlı RT-DETR mimarisinde kullanılan "Hybrid Encoder" yapısının etkisi detaylıca incelenmiştir. Araştırma, bu hibrit yapının ölçek-içi özellik etkileşimi (intra-scale feature interaction) sağlayarak, farklı boyutlardaki nesnelerin (özellikle küçük patolojik bölgelerin) tespitinde geleneksel CNN tabanlı modellerden daha yüksek bir hassasiyet sunduğunu kanıtlamaktadır. Çalışmanın en önemli başarısı, modelin "Non-Maximum Suppression" (NMS) gibi işlem yükünü artıran son işleme adımlarına duyduğu ihtiyacı ortadan kaldırarak hem hızı hem de doğruluğu aynı anda optimize etmesidir[19].nesnetespit4

Chen vd. (2024) tarafından gerçekleştirilen çalışmada, BT taramalarında böbrek taşı tespiti için evrişimli yapılar ile dikkat mekanizmalarını birleştiren Attention-YOLO hibrit mimarisi önerilmiştir. Araştırmada, YOLO mimarisine entegre edilen dikkat bloklarının, böbrek anatomisi içerisindeki patolojik bölgeleri çevresel dokulardan ayırt etme yeteneği ve modelin odaklanma hassasiyeti test edilmiştir. Çalışmanın en önemli başarısı, dikkat mekanizmalarının eklenmesiyle modelin yanlış pozitif (FP) oranını düşürmesi ve küçük boyutlu taşları yakalamadaki başarısını artırmasıdırnesnetespit5[20].

İncelenen tüm çalışmalar birlikte değerlendirildiğinde, literatürdeki mevcut yaklaşımların yüksek teknik başarı göstermelerine rağmen klinik entegrasyon, yapısal hibritleşme ve etkileşimli kullanıcı deneyimi gibi kritik alanlarda projemizin sunduğu kapsamdan uzak kaldığı görülmektedir. Literatürdeki geleneksel yaklaşımlar incelendiğinde;[3] ve[12] gibi çalışmaların Back-Propagation Neural Network (BPN) ve Gray Level Co-occurrence Matrix (GLCM) gibi daha geleneksel yöntemlere odaklandığı, ancak modern derin öğrenme mimarilerinin sağladığı genelleme yeteneğinden yoksun olduğu saptanmıştır. Benzer şekilde,[4] ve [11] tarafından önerilen yöntemler temel görüntü işleme ve Level Set segmentasyonuna dayanırken, [14] Probabilistic Neural Network (PNN) ve Watershed algoritmasını kullanmış; fakat bu çalışmaların tamamı BT görüntülerindeki karmaşık doku farklılıklarını anlamlandırabilecek uçtan uca öğrenme süreçlerini ve global bağlamı ihmal etmiştir.

Daha güncel derin öğrenme temelli sınıflandırma yaklaşımları olan [7], [13] ve [5] çalışmalarında VGG ve ResNet gibi güçlü CNN mimarileri kullanılarak yüksek doğruluk oranlarına ulaşılsa da, bu modellerin yerel özellik çıkarımı ile sınırlı kalması, projemizde önerilen Transformer tabanlı küresel dikkat mekanizmalarının sunduğu anatomik bütünlük analizini eksik bırakmaktadır. [2] çalışmasında CNN tabanlı bir tespit sunmuş, ancak [8] tarafından vurgulanan hacimsel segmentasyon ve klinik karar destek ihtiyacını karşılayacak bir interaktif arayüz vizyonu geliştirmemiştir. Veri artırma ve dikkat mekanizmaları üzerine yoğunlaşan [1], [6], [9] ve [10] gibi derleme ve teknik çalışmalar ise yöntemlerin önemini kanıtlamakla birlikte, hekimlerin günlük iş akışına dahil olabilecek somut bir yazılım çözümü sunmamaktadır.

Nesne tespiti odaklı en güncel literatürde ise; [15] tarafından sunulan RT-DETR modeli gerçek zamanlı performansta başarılı olsa da, klinik raporlama sürecini otomatize eden bir dil modeli (LLM) entegrasyonu içermemektedir. [17] YOLOv11 ve U-Net

kombinasyonu ile segmentasyon başarısını artırmış, ancak nesne tespiti modellerinin temel kısıtı olan Non-Maximum Suppression (NMS) yükünü ve interaktif diyalog mekanizmalarını ele almamıştır. [19] dikkat tabanlı çok yollu özellik füzyonu kullanarak küçük objelerin tespitine odaklanmış; [20], [18] ve [16] ise sırasıyla D2ETR, DINO ve Deformable DETR gibi mimarilerle hesaplama verimliliği sağlamışlardır. Ancak bu ileri düzey teknik modellerin hiçbirinde, projemizde merkezi bir konumda bulunan ve radyologların model kararlarını sorgulayabileceği, doğal dil işleme tabanlı etkileşimli chatbot modülü ve açıklanabilir yapay zeka (XAI) araçları bulunmamaktadır. Sonuç olarak projemiz, literatürdeki bu teknik parçalanmışlığı; FCM tabanlı dinamik ön-ışleme, CNN-Transformer hibrit mimarisi ve hekim odaklı diyalog tabanlı raporlama sistemiyle bütünleştirerek özgün ve klinik değeri yüksek bir çözüm sunmaktadır.

1.4 Projenin Amacı

Bu araştırmanın temel amacı, BT görüntülerinde böbrek taşlarının otomatik tespiti için farklı derin öğrenme mimarilerini (CNN, Transformer ve Hibrit modeller) karşılaştırmalı olarak analiz etmektir. Proje, sadece yüksek doğruluk oranlarına ulaşmayı değil, aynı zamanda görsel açıklanabilirlik teknikleri kullanarak model kararlarını radyologlar için güvenilir ve yorumlanabilir hale getirmeyi hedeflemektedir. Son aşamada ise bu algoritmaların klinik iş akışına entegrasyonunu simüle eden kullanıcı dostu bir karar destek prototipi geliştirilmesi amaçlanmaktadır.

2 Yöntem

2.1 Veri Seti

Araştırmanın başlangıç aşamasında, model mimarilerinin optimizasyonu için Kaggle platformunda bulunan ve anonimleştirilmiş BT görüntülerinden oluşan "Kidney Stone Images with Bounding Box Annotations" veri seti kullanılacaktır [21]. Bu veri seti; normal ve taş vakalarını içeren verilere sahiptir. İlerleyen süreçte, modelin gerçek dünya genelleme yeteneğini artırmak amacıyla etik izinler dahilinde yerel hastanelerden temin edilecek gerçek klinik verilerin sürece dahil edilmesi planlanmaktadır.

2.2 Görüntü Ön-İşleme

Modellerin eğitim sürecinde yakınsama hızını artırmak ve farklı kaynaklardan gelen veriler arasındaki varyansı minimize etmek amacıyla ham BT görüntüleri üzerinde kapsamlı bir ön-ışleme hattı uygulanacaktır.

2.2.1 Yoğunluk Standardizasyonu ve Normalizasyon

BT görüntüleri, farklı tarayıcı parametreleri ve protokolleri nedeniyle geniş bir piksel yoğunluğu aralığına sahiptir. Modelin ağırlık güncellemelerinin kararlı olması için tüm piksel değerleri $[0, 1]$ aralığına doğrusal olarak ölçeklenecektir. Bu amaçla Min-Max Normalizasyonu yöntemi kullanılacaktır. İşlem, her bir piksel değeri için aşağıdaki

formüle göre gerçekleştirilir:

$$X_{norm} = \frac{X - X_{min}}{X_{max} - X_{min}} \quad (1)$$

Burada X , orijinal piksel değerini; X_{min} ve X_{max} ise veri setindeki ilgili görüntüye veya tüm veri setine ait minimum ve maksimum yoğunluk değerlerini temsil etmektedir. Bu sayede, görüntüdeki kontrast korunurken sayısal değerler derin öğrenme mimarileri için optimize edilmiş olur.

2.2.2 Gürültü Giderme

BT cihazlarından elde edilen görüntüler, çekim anındaki saçılma radyasyonu veya elektronik gürültüler nedeniyle "tuz-biber gürültüsü" (salt-and-pepper noise) gibi bozunmalar içerebilir. Bu durum, özellikle böbrek taşı gibi küçük ve parlak yapıların sınırlarının belirsizleşmesine yol açar. Görüntü kalitesini artırmak için: Medyan Filtreleme: Her pikselin değeri, komşuluk matrisindeki değerlerin medyanı ile değiştirilerek kenar bilgileri korunurken gürültülerin elenmesi sağlanacaktır.

2.2.3 Boyutlandırma

Tüm görüntüler, seçtiğimiz modelin giriş gereksinimlerine uygun olarak standart boyutlara getirilecektir.

2.3 Veri Etiketleme

Projenin nesne tespiti (object detection) odaklı yapısı, veri setindeki her bir görüntünün sadece sınıf bilgisini değil, aynı zamanda patolojik bölgenin (böbrek taşı) mekânsal konumunu da içermesini gerektirmektedir. Sınıflandırma modellerinden farklı olarak, RT-DETR ve YOLO mimarilerinin eğitimi için "taş var/yok" etiketine ek olarak, taşın koordinatlarını belirleyen "Bounding Box" (Sınırlayıcı Kutu) etiketleme süreci yürütülecektir.

2.3.1 Etiketleme Formatı

Görüntüler, RT-DETR mimarisinin eğitim gereksinimlerine uygun olarak COCO (Common Objects in Context) veya nesne tespiti literatüründe standart kabul edilen YOLO formatında etiketlenecektir. Her bir etiket dosyası; nesnenin sınıf bilgisini (Taş), kutunun merkez koordinatlarını (x, y) ve kutunun genişlik/yükseklik (w, h) değerlerini içerecektir.

2.3.2 Mekânsal Doğruluk

Radyologlar tarafından doğrulanan taşlı kesitlerde, her bir taşın etrafına en dar sınırlayıcı kutu manuel veya yarı-otomatik araçlarla çizilecektir. Bu sayede model, görüntünün genelindeki dokusal özellikler yerine doğrudan taş piksellerine ve bu piksellerin çevresel anatomik bağlamına odaklanmayı öğrenecektir.

2.3.3 Çoklu Nesne Tespiti

Tek bir BT kesitinde birden fazla taş bulunması durumunda, her bir patoloji ayrı ayrı etiketlenerek modelin karmaşık vakalarda yüksek hassasiyetle çalışması hedeflenmektedir. Bu yaklaşım, ilgili makale tarafından önerilen RT-DETR tabanlı çoklu taş tahmini stratejisiyle paralellik göstermektedir[15]. Bu etiketleme süreci, modelin sadece "neye baktığını" değil, "nereye baktığını" da anlamasını sağlayarak; "tespit" işlevinin matematiksel temelini oluşturmaktadır.

2.4 Bölge Belirleme

Böbrek dışındaki dokuların (kemik, kas, yağ vb.) model üzerindeki yanıltıcı etkisini azaltmak için bölge belirleme adımı uygulanacaktır. Bu kapsamda klasik görüntü işleme yöntemlerinden *FCM* Kümeleme ve *Level Set* Segmentasyonu kullanılarak böbrek bölgesi izole edilecektir. Elde edilen bu maskelenmiş görüntüler ROI, modelin sadece ilgili patolojik alanlara odaklanmasını sağlayacaktır.

2.4.1 Fuzzy C-Means (FCM) Kümeleme

FCM, piksellerin birden fazla kümeye belirli bir üyelik derecesiyle ait olabildiği bir kümeleme algoritmasıdır. BT görüntülerinde yumuşak doku geçişlerini modellemek için kullanılan maliyet fonksiyonu (J_m) aşağıdaki gibidir:

$$J_m = \sum_{i=1}^N \sum_{j=1}^C u_{ij}^m \|x_i - v_j\|^2 \quad (2)$$

Burada u_{ij} , x_i pikselinin j . kümeye olan üyelik derecesini; v_j küme merkezini ve m bulanıklık katsayısını temsil etmektedir. Bu yöntemle böbrek dokusuna ait bir maske elde edilecektir.

2.4.2 Level Set Segmentasyonu

FCM ile elde edilen maske, *Level Set* yöntemiyle anatomik sınırlara tam uyumlu hale getirilecektir. Bu yöntemde kontur evrimi, konturun hareket hızını belirleyen bir diferansiyel denklem ile ifade edilir.

$$\frac{\partial \phi}{\partial t} = F|\nabla \phi| \quad (3)$$

Burada ϕ seviye kümesi fonksiyonunu, F ise görüntüdeki gradyan ve yoğunluk bilgilerine göre konturun yayılma hızını temsil eder. Bu süreç, konturun böbrek sınırlarına veya taş gibi yüksek yoğunluklu patolojilere ulaştığında durmasını sağlayarak hassas koordinat çıkarımına olanak tanır.

2.5 Veri Artırma

Modelin aşırı uyum yapmasını önlemek ve kısıtlı tıbbi veriyle daha dayanıklı sonuçlar elde etmek için veri artırma teknikleri kullanılacaktır. Görüntüler üzerinde; döndürme (rotation), ölçekleme (scaling), aydınlık-kontrast değişimi ve yapay gürültü ekleme gibi manipülasyonlar uygulanarak veri çeşitliliği sentetik olarak artırılacaktır.

2.6 Derin Öğrenme

Proje kapsamında kullanılacak en uygun mimariyi belirlemek amacıyla, literatürde öne çıkan sınıflandırma ve nesne tespiti yaklaşımları detaylıca incelenmiştir. Önceki değerlendirmelerimizde üzerinde durulan XResNet-50, ResNet ve DenseNet gibi CNN tabanlı sınıflandırma modelleri, her ne kadar %96.82 gibi yüksek doğruluk oranlarına ulaşsa da, klinik pratikte sadece "taş var/yok" bilgisi sunmaları nedeniyle sınırlı kalmaktadır. Patolojinin sadece varlığını değil, görüntünün üzerindeki tam koordinatlarını (Bounding Box) belirleyebilen nesne tespiti modellerine odaklanılmıştır. XResNet-50 gibi sınıflandırma modellerinin aksine nesne tespiti yaklaşımı, taşın lokasyonunu ve boyutunu tam olarak saptayarak cerrahi planlama aşamasında doktora hayati önem taşıyan mekânsal bilgiyi sunma kapasitesine sahiptir.

Bu bağlamda, literatürde yaygın olarak kullanılan YOLO (You Only Look Once) serisi modeller ile en güncel Transformer tabanlı nesne tespiti modeli olan RT-DETR (Real-Time Detection Transformer) karşılaştırılmıştır. Geleneksel YOLO mimarileri, aday bölgeleri belirlemek için "Non-Maximum Suppression" (NMS) adı verilen ve işlem yükünü artıran bir son işleme adımına ihtiyaç duyarken; RT-DETR mimarisi uçtan uca (end-to-end) yapısı sayesinde NMS gereksinimini ortadan kaldırmaktadır. Bu teknolojik fark, sadece işlem süresini (latency) optimize etmekle kalmamakta, aynı zamanda tahmin doğruluğunu da artırmaktadır. Ayrıca, YOLO modellerinin yerel özelliklere odaklanan yapısına karşın, RT-DETR bünyesindeki "Hybrid Encoder" yapısı sayesinde BT görüntülerindeki küresel anatomik bağlamı ve uzun menzilli bağımlılıkları çok daha etkin bir şekilde analiz edebilmektedir.

Yapılan analizler sonucunda, özellikle küçük boyutlu taşları yakalamadaki yüksek hassasiyeti ve gerçek zamanlı işlem yeteneği nedeniyle projenin ana omurgasını oluşturacak model olarak RT-DETR seçilmiştir. Bu modelin kullanımıyla, "taşı tespit etme" kriteri matematiksel ve teknik bir temele oturtulmuştur. Geliştirme sürecinde RT-DETR modelinden elde edilen sonuçlar, literatürdeki YOLOv8 ve YOLOv11 gibi güncel modellerin başarılarıyla karşılaştırmalı olarak analiz edilecek ve projenin sunduğu özgün değer bu nicel verilerle raporlanacaktır.

2.7 Eğitim Ve Değerlendirme

Modellerin eğitim süreci, yüksek genelleme kabiliyetine sahip ve klinik olarak güvenilir sonuçlar üretecek şekilde yapılandırılacaktır. Eğitim sırasında karşılaşılan en büyük zorluklardan biri olan aşırı uyum problemini önlemek adına, modelin doğrulama hatasının artmaya başladığı noktada eğitimi sonlandıran erken durdurma (early stopping) ve veri setinin farklı varyasyonlarıyla test edilmesini sağlayan çapraz doğrulama (k-fold validation) stratejileri uygulanacaktır. Tüm model aileleri (CNN, Transformer ve Hibrit); öğrenme oranı (learning rate), yığın boyutu (batch size) ve epoch sayısı gibi hiper-parametreler açısından eşit koşullarda eğitilerek performanslarının nesnel bir zeminde karşılaştırılması sağlanacaktır.

Eğitilen modellerin başarısı, sadece genel doğruluk (Accuracy) oranıyla değil, tıbbi teşhis süreçleri için kritik önem taşıyan çok boyutlu metriklerle değerlendirilecektir:

Duyarlılık (Sensitivity/Recall): Modelin gerçek pozitif vaka olan böbrek taşlarını doğru tanıma oranı ölçülecektir.

Özgüllük (Specificity/TNR): Modelin sağlıklı dokuları hatalı bir şekilde taş olarak sınıflandırma (yanlış pozitif) eğilimi analiz edilecektir.

F1-Skoru: Duyarlılık ve kesinlik (Precision) değerleri arasında denge kurularak, özellikle dengesiz veri dağılımlarında model başarısının daha adil bir şekilde ölçülmesi sağlanacaktır.

Alıcı İşletim Karakteristiği (ROC) ve Eğri Altı Alan (AUC): Modellerin farklı eşik değerlerindeki ayırma gücü görsel ve nicel olarak incelenerek, klinik güvenilirlik seviyeleri karşılaştırılacaktır.

Bu değerlendirme süreci sonunda, her modelin hata matrisi (Confusion Matrix) üzerinden hangi patolojileri daha yüksek doğrulukla tespit ettiği belirlenerek en verimli çözüm seçilecektir.

2.7.1 Çapraz Doğrulama (k-fold Cross-Validation) Stratejisi

Modelin eğitim sürecinde verinin sadece belirli bir kısmına odaklanıp ezberlemesini (*aşırı uyum*) engellemek ve kısıtlı tıbbi veri setinden maksimum verimi almak amacıyla k-katlı çapraz doğrulama yöntemi kullanılacaktır. Bu yöntemde, veri seti rastgele k eşit parçaya bölünür. Her iterasyonda bir parça test/doğrulama seti olarak ayrılırken, geri kalan $k - 1$ parça eğitim süreci için tahsis edilir.

Listing 1 Stratified K-Fold Çapraz Doğrulama Algoritma Yapısı

```
# Girdi:
# VeriSeti  -> Tüm örnekler ve etiketler
# K        -> Fold sayısı

BasariListesi = []

# 1. Veri seti K esit parcaya bolunur
Foldlar = VeriSetiniBol(VeriSeti, K)

# 2. Capraz dogrulama dongusu
for i in range(1, K+1):

    # 2.1 Bir parca test, digerleri egitim verisi olur
    TestVerisi = Foldlar[i]
    EgitimVerisi = TumFoldlar - Foldlar[i]

    # 2.2 Model sifirdan egitilir
    Model = ModelOlustur()
    Model.Egit(EgitimVerisi)

    # 2.3 Test verisi uzerinde tahmin yapilir
    Tahminler = Model.Test(TestVerisi)

    # 2.4 Performans hesaplanir
```

```
Basari = PerformansHesapla(Tahminler, TestVerisi)
```

```
BasariListesi.append(Basari)
```

```
# 3. Nihai basari degeri
```

```
OrtalamaBasari = Ortalama(BasariListesi)
```

Bu döngü sayesinde veri setindeki her örnek hem eğitim hem de doğrulama aşamalarında yer almış olur. Her fold sonunda elde edilen F1-skoru, duyarlılık ve doğruluk değerlerinin aritmetik ortalaması alınarak modelin nihai performans raporu oluşturulacaktır. Bu yaklaşım, modelin daha önce karşılaşmadığı gerçek klinik veriler üzerindeki genelleme yeteneğini bilimsel bir temelde simüle etmemize olanak tanır.

3 Beklenen Sonuçlar

3.1 Performans Ölçütleri

Geliştirilen modellerin başarısını ve genelleme kabiliyetini nesnel bir zeminde değerlendirmek amacıyla kapsamlı bir tıbbi performans metriği hattı kullanılacaktır. Nesne tespiti (object detection) tabanlı yaklaşımların hem sınıflandırma hem de mekânsal yerleştirme isabetini ölçmek için model başarısı, klinik gereksinimler doğrultusunda aşağıdaki analiz yöntemleri ile nicelendirilecektir:

- **Nesne Tespiti Metrikleri:** Sınıflandırma başarısının ötesinde, modelin mekânsal tespit hassasiyetini ölçmek için iki temel metrik kullanılacaktır:
 - **Intersection over Union (IoU):** Model tarafından tahmin edilen sınırlayıcı kutu ile radyolog tarafından işaretlenen gerçek kutunun çakışma oranını ifade eder. Bu değer, taşın konumunu ve boyutunu ne kadar isabetli belirlediğimizin temel göstergesidir.
 - **Mean Average Precision (mAP):** Farklı IoU eşik değerleri için hesaplanan ortalama kesinlik değeridir. Yüksek mAP değeri, RT-DETR modelinin taşları hem doğru sınıflandırdığını hem de yüksek mekânsal hassasiyetle yerleştirdiğini kanıtlamaktadır.
- **Sayısal Analiz:** Eğitim ve test süreçleri sonunda her mimari için Accuracy, Sensitivity (Hassasiyet), Specificity (Özgüllük), Precision (Kesinlik), F1-Skoru ve Matthews Korelasyon Katsayısı (MCC) değerleri hesaplanarak karşılaştırmalı tablolar halinde sunulacaktır.
- **Grafiksel Değerlendirme:** Modellerin öğrenme kararlılığını ve yakınsama hızını izlemek amacıyla epoch bazlı Accuracy ve Loss grafikleri oluşturulacaktır. Ayrıca, sınıflandırma eşiklerinin performansını ve modellerin ayırım gücünü görselleştirmek için ROC eğrileri çizilecek ve AUC değerleri raporlanacaktır.
- **Hata Matrisi (Confusion Matrix):** Model tahminlerinin sınıf bazlı dağılımı; Doğru Pozitif (TP), Yanlış Pozitif (FP), Doğru Negatif (TN) ve Yanlış Negatif (FN) parametreleri üzerinden görselleştirilecektir. Bu analizde, özellikle yanlış negatiflerin (patolojinin gözden kaçması) teşhis süreçlerindeki klinik riski derinlemesine tartışılacaktır.

3.2 Açıklanabilirlik Analizi

Derin öğrenme modellerinin "kara kutu" olarak nitelendirilen yapısını şeffaflaştırmak ve tıbbi güvenilirliği sağlamak adına bu çalışmada görsel açıklanabilirlik teknikleri kullanılacaktır. Sınıflandırma modellerinden farklı olarak, nesne tespiti (object detection) mimarisi olan RT-DETR'in sunduğu mekânsal verileri doktora şu yöntemlerle sunulacaktır:

- **Dikkat Haritaları:** RT-DETR modeli, Transformer tabanlı bir mimariye sahip olduğu için nesne tespiti sırasında "Self-Attention" ve "Cross-Attention" mekanizmalarından yararlanmaktadır. Bu mekanizmalar aracılığıyla üretilen dikkat haritaları, modelin görüntünün hangi anatomik bölgelerine odaklanarak "taş" kararını verdiğini ve koordinatları nasıl belirlediğini görselleştirecektir. Bu sayede, modelin yanıltıcı çevre dokular yerine doğrudan patolojik alana yoğunlaştığı matematiksel olarak kanıtlanacaktır.
- **Sınırlayıcı Kutular ve Görsel İşaretleme:** Model, tespit ettiği her bir böbrek taşının etrafına çizdiği koordinat bazlı sınırlayıcı kutular ile patolojinin tam konumunu ve yaklaşık boyutunu doktora sunar. Sadece "taş var" bilgisi yerine sunulan bu lokasyon verisi, cerrahi müdahale planlamasında ve klinik karar verme sürecinde somut bir destek sağlayacaktır.
- **Klinik Validasyon ve IoU Tabanlı Doğrulama:** Model tarafından üretilen sınırlayıcı kutular ve dikkat haritaları, uzman radyologların manuel işaretlemeleri ile üst üste bindirilerek karşılaştırılacaktır. IoU, sistemin "Anatomik Doğruluk" seviyesini belirleyecek ve teknik hata analizlerinde temel veri olarak kullanılacaktır.

3.3 Karar Destek Sistemi

Bu proje kapsamında geliştirilen RT-DETR tabanlı böbrek taşı nesne tespiti modelinin, klinik kullanım senaryolarına uygun biçimde değerlendirilebilmesi amacıyla kullanıcı dostu bir karar destek sistemi tasarlanacaktır. Bu sistem, radyologların ve ürologların BT görüntülerini sadece sınıflandırmakla kalmayıp, patolojik bölgelerin tam lokasyonunu ve boyutlarını hızlı biçimde analiz edebileceği bir arayüz sunmayı hedeflemektedir.

Geliştirilecek karar destek sistemi; kullanıcı tarafından yüklenen BT görüntüsü üzerinde eğitilmiş RT-DETR modelinin gerçek zamanlı çıkarım yapmasını sağlayacaktır. Sistem, geleneksel sınıflandırma sonuçlarının ötesine geçerek, tespit edilen her bir böbrek taşını orijinal görüntü üzerinde sınırlayıcı kutular ile işaretleyecektir. Buna ek olarak, modelin taşın konumunu belirlerken kullandığı Transformer tabanlı dikkat haritaları görselleştirilerek, modelin kararına temel teşkil eden anatomik odak noktaları doktora şeffaf bir biçimde sunulacaktır.

Karar destek sistemi kapsamında ayrıca, modelin ürettiği nesne tespiti verilerini metin tabanlı olarak özetleyen ve yorumlayan bir chatbot modülü entegre edilecektir. Bu modül, tespit edilen taşların görüntünün hangi kesitinde ve tam olarak hangi böbrek bölgesinde yer aldığını kısa bir rapor halinde sunabilecek; modelin ürettiği teknik çıktılar üzerinden gelen bağlamli sorulara yanıt verebilecektir. Böylece sistem, doktorların cerrahi planlama öncesinde tam sürecini hızlandırmasına ve radyolojik raporlama sürecini otomatize etmesine yardımcı olacaktır.

Sonuç olarak geliştirilecek bu karar destek sistemi, RT-DETR mimarisinin sunduğu mekânsal tespit gücünü kullanıcı etkileşimi ve görsel açıklanabilirlik bileşenleri ile birleştirerek, böbrek taşı tespiti ve lokalizasyonuna yönelik pratik, güvenilir ve klinik açıdan anlamlı bir prototip sunmayı amaçlamaktadır.

Kaynakça

- [1] Xie, Y., Yang, B., Guan, Q., Zhang, J., Wu, Q., Xia, Y.: Attention mechanisms in medical image segmentation: A survey. arXiv preprint arXiv:2305.17937 (2023)
- [2] Santhosh, S., Shenoy, A., Akhila, D., *et al.*: Deep learning based kidney stone detection using ct scan images. In: 2023 First International Conference on Advances in Electrical, Electronics and Computational Intelligence (ICAEECT), pp. 1–7 (2023). IEEE
- [3] Akshaya, M., Nithushaa, R., Raja, N.S.M., Padmapriya, S.: Kidney stone detection using neural networks. In: 2020 International Conference on System, Computation, Automation and Networking (ICSCAN), pp. 1–4 (2020). IEEE
- [4] Rajput, S., Singh, A., Gupta, R.: Automated kidney stone detection using image processing techniques. In: 2021 9th International Conference on Reliability, Infocom Technologies and Optimization (Trends and Future Directions)(ICRITO), pp. 1–5 (2021). IEEE
- [5] Yildirim, K., Bozdog, P.G., Talo, M., Yildirim, O., Karabatak, M., Acharya, U.R.: Deep learning model for automated kidney stone detection using coronal ct images. *Computers in biology and medicine* **135**, 104569 (2021)
- [6] Chlap, P., Min, H., Vandenberg, N., Dowling, J., Holloway, L., Haworth, A.: A review of medical image data augmentation techniques for deep learning applications. *Journal of medical imaging and radiation oncology* **65**(5), 545–563 (2021)
- [7] Vishmitha, D., Yoshika, K., Sivalakshmi, P., Shanthi, K., Yamini, M., *et al.*: Kidney stone detection using deep learning and transfer learning. In: 2022 4th International Conference on Inventive Research in Computing Applications (ICIRCA), pp. 987–992 (2022). IEEE
- [8] Elton, D.C., Turkbey, E.B., Pickhardt, P.J., Summers, R.M.: A deep learning system for automated kidney stone detection and volumetric segmentation on noncontrast ct scans. *Medical Physics* **49**(4), 2545–2554 (2022)
- [9] Goceri, E.: Medical image data augmentation: techniques, comparisons and interpretations. *Artificial intelligence review* **56**(11), 12561–12605 (2023)
- [10] Nagaraju, M., Chawla, P., Kumar, N.: Performance improvement of deep learning models using image augmentation techniques. *Multimedia Tools and Applications*

- [11] Akkasaligar, P.T., Biradar, S., Kumbar, V.: Kidney stone detection in computed tomography images. In: 2017 International Conference on Smart Technologies for Smart Nation (SmartTechCon), pp. 353–356 (2017). IEEE
- [12] Mishr, R., Bhattacharjee, A., Gayathri, M., Malathy, C.: Kidney stone detection with ct images using neural network. International Journal of Psychosocial Rehabilitation **24**(8), 2490–2497 (2020)
- [13] Manoj, B., Mohan, N., Kumar, S., *et al.*: Automated detection of kidney stone using deep learning models. In: 2022 2nd International Conference on Intelligent Technologies (CONIT), pp. 1–5 (2022). IEEE
- [14] S, S.R.B., G, M., Sherly, E.: Kidney stone detection from ct images using probabilistic neural network(pnn) and watershed algorithm. In: 2023 International Conference on Advances in Intelligent Computing and Applications (AICAPS), pp. 1–6 (2023). <https://doi.org/10.1109/AICAPS57044.2023.10074562>
- [15] Vasanthi, P., Srinivasu, L.N., Teju, V., Sowmya, K.V., Stan, A., Sita, V., Miclea, L., Stan, O.: Multiple kidney stones prediction with efficient rt-detr model. Computers in Biology and Medicine **190**, 110023 (2025)
- [16] Zhu, X., Su, W., Lu, L., Li, B., Wang, X., Dai, J.: Deformable DETR: Deformable Transformers for End-to-End Object Detection (2021). <https://arxiv.org/abs/2010.04159>
- [17] Boriceanu, I., Popescu, D., Ichim, L.: Kidney stone detection and segmentation using a yolo v11+ unet pipeline. In: 2025 33rd Mediterranean Conference on Control and Automation (MED), pp. 179–184 (2025). IEEE
- [18] Zhang, H., Li, F., Liu, S., Zhang, L., Su, H., Zhu, J., Ni, L.M., Shum, H.-Y.: Dino: Detr with improved denoising anchor boxes for end-to-end object detection. arXiv preprint arXiv:2203.03605 (2022)
- [19] Sri, V.S., GR, J.L.: Kidney stone detection in ct scans using attention based multi-path feature fusion networks. Engineering Research Express **7**(3), 035272 (2025)
- [20] Lin, J., Mao, X., Chen, Y., Xu, L., He, Y., Xue, H.: D²ETR: Decoder-Only DETR with Computationally Efficient Cross-Scale Attention (2022). <https://arxiv.org/abs/2203.00860>
- [21] Safurahajiheidari: Kidney Stone Images with Bounding Box Annotations. Kaggle (2024). <https://www.kaggle.com/datasets/safurahajiheidari/kidney-stone-images>